Séance 1 - Projet S6

1 Introduction

On travaille avec des couples (x_i, y_i). Le but est de faire des régressions, c'est-à-dire de chercher à expliquer la variable aléatoire Y_i en fonction des x_i.

On cherche la fonction f telle que :

$$Y_i = f(x_i) + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma^2) \tag{1}$$

Le terme ϵ_i exprime l'aléa dans le modèle : il n'existe pas réellement une relation déterministe entre les Y_i et les X_i. L'objectif est de trouver la meilleure fonction f qui se rapproche au mieux des données.

2 Méthode

Les jeux de données utilisés proviendront d'un simulateur boîte noire. L'objectif des régressions est donc d'estimer la fonction f à partir d'un nombre fini d'observations et de sorties. Cela est réalisé en utilisant la méthode des processus gaussiens.

Nous éviterons d'utiliser des bibliothèques toutes faites, préférant repartir de notre propre implémentation, même si cela réduit les fonctionnalités disponibles.

2.1 Exemple simple

Sans bruit ($\epsilon = 0$), on peut approximer une courbe avec 6 points et fournir des intervalles de confiance. L'incertitude sur le résultat augmente lorsque l'on s'éloigne des points connus.

Avec du bruit, les données ne se situent pas sur la courbe exacte (qui correspond à la valeur moyenne des sorties). À une valeur x donnée, on prend l'espérance des y correspondants. Cette approche permet de tracer a posteriori la courbe, qui diffère d'une simple interpolation.

3 Hypothèses sur la fonction f

La méthode de régression sert aussi à lisser les données. Les sorties réelles présentent des variations, et il faut trouver un compromis entre le lissage de f et la précision des estimations.

Les paramètres définissant le degré de lissage peuvent être trouvés automatiquement à partir des données. Au début, ils seront fixés arbitrairement et traduiront des informations a priori sur f.

4 Processus gaussiens

Si ξ est la fonction inconnue, on considère une loi a priori :

$$\xi \sim GP(m, k) \tag{2}$$

avec m la moyenne et k la covariance.

En particulier, nous avons :

$$(\xi(x_1), \ldots, \xi(x_n))^T \sim \mathcal{N}\Big((m(x_1), \ldots, m(x_n))^T, \mathrm{Mat}(k(x_i, x_j))\Big) \tag{3}$$

Souvent, on prend $m = 0$.

Les observations sont des couples $(x_1, y_1), \ldots, (x_n, y_n)$, notés F_n.

La distribution conditionnelle de $\xi(x^*)$ sachant F_n est donnée par :

$$\xi(x^*)|F_n \sim \mathcal{N}(m_n(x^*), \sigma_n^2(x^*)) \tag{4}$$

avec :

$$m_n(x^*) = k(x^*, x_n)(K_n + \sigma^2 I_n)^{-1} y_n \tag{5}$$

et

$$\sigma_n^2(x^*) = k(x^*, x^*) - k(x^*, x_n) K_n^{-1} k(x_n, x^*) \tag{6}$$

où : - $k(x^*, x_n)$ est un vecteur ligne de taille n, - K_n est une matrice $n \times n$ avec $(k(x_i, x_j))$, - y_n est un vecteur colonne $(y_1, \ldots, y_n)$.

5 Problèmes liés aux grandes dimensions

Lorsque n est grand, la matrice K_n devient trop volumineuse à stocker et à inverser. Par exemple, pour 30000 points, K_n occupe 3 Go en mémoire. Nous étudierons des méthodes pour gérer ces limitations.

Une approche classique est la factorisation de Cholesky, utilisée pour résoudre des systèmes linéaires lorsque K_n est symétrique définie positive. Cependant, elle a un coût en $\mathcal{O}(n^3)$, ce qui devient vite prohibitif.

Nous examinerons d'autres méthodes, comme la factorisation de Cholesky incomplète.

6 Travaux à réaliser

Les premières étapes du projet sont :

1. Réviser les vecteurs gaussiens aléatoires et la notion de densité conditionnelle.

2. Implémenter la méthode en une dimension avec un petit n, en choisissant un jeu de données arbitraire.

3. Étudier la factorisation de Cholesky et son utilisation pour résoudre des systèmes linéaires.