Régression par processus gaussiens avec un grand nombre d'observations : application à l'émulation bayésienne de simulateurs stochastiques

Encadrant : Julien Bect (julien.bect@centralesupelec.fr).
Département de Mathématiques (CentraleSupélec).
Laboratoire des Signaux & Systèmes (Univ. Paris-Saclay, CNRS, CentraleSupélec).

Vous aimez les données, l'algèbre linéaire, le camembert et les bouquetins ?
Ne cherchez pas plus loin, ce projet est fait pour vous !

Simulateurs stochastiques et émulation

Les simulateurs stochastiques (voir par exemple Baker et al., 2022) sont des modèles numériques conçus pour représenter des systèmes complexes intégrant des éléments aléatoires ou incertains. Utilisés dans des domaines variés tels que les sciences de l'environnement, la finance ou l'ingénierie, ces simulateurs sont essentiels pour comprendre, prédire et optimiser des phénomènes où des solutions analytiques directes sont souvent impossibles à obtenir. Leur pertinence réside dans leur capacité à explorer des scénarios incertains et à fournir des informations utiles pour la prise de décision.

Problème : les modèles numériques, qu'ils soient stochastiques ou non, sont souvent d'autant plus coûteux en ressources informatiques (temps de calcul par exemple) qu'ils sont réalistes et précis. L'émulation d'un modèle numérique consiste à créer, pour répondre à cette difficulté, une approximation rapide et fiable du simulateur original, de façon à pouvoir mener plus efficacement diverses analyses — analyse de sensibilité, calibration des paramètres ou encore optimisation. La construction d'un émulateur consiste à « apprendre », à partir d'une base de simulations déjà disponible ou construite séquentiellement, la relation entre les entrées et les sorties du simulateur : il s'agit donc d'un problème qui relève du domaine de l'apprentissage statistique.

Dans la cas particulier des simulateurs stochastiques, un émulateur peut être vu comme un modèle génératif, permettant de générer à moindre coût des échantillons aléatoires statistiquement indistinguables (idéalement) de ceux qu'aurait pu générer le simulateur original avec les mêmes entrées — de la même façon qu'un robot conversationnel vise à produire, étant donné une invite, des réponses indistinguables de celles qu'auraient pu donner un être humain dans les mêmes circonstances.

Deux exemples

On s'intéressera plus particulièrement, dans ce projet, à l'émulation de deux simulateurs stochastiques particuliers.

Le premier (Basak, 2024) s'intéresse à l'analyse quantitative des risques (AQR) microbiologiques liés à la consommation de fromage de type pâte molle au lait cru, comme le Camembert de

Normandie. Ce simulateur stochastique est conçu pour estimer l'impact des maladies d'origine alimentaire sur la santé publique, causées par des agents pathogènes tels que *Escherichia coli* entérohémorragiques (EHEC), *Salmonella* et *Listeria monocytogenes*, potentiellement présents dans ce type de fromage. Il s'agit d'un modèle *farm-to-fork*, qui représente l'intégralité de la chaîne depuis la collecte du lait à la ferme (lieu de la contamination potentielle) jusqu'à la consommation.

Le second modélise la propagation de la bruxellose chez les bouquetins des Alpes (*Capra ibex*) du massif du Bargy, en Haute-Savoie (Lambert et al., 2023). La brucellose, ou fièvre de Malte, est une maladie infectieuse, due à des bactéries du genre *Brucella* — en l'occurence, *Brucella melitensis*. Elle touche les ruminants domestiques et sauvages, ainsi que d'autres mammifères, dont les humains. La bruxellose avait officiellement disparu de France depuis 2005, mais deux cas humains en Haute-Savoie en 2012 ont conduit à la découverte de l'infection dans un élevage bovin et chez les bouquetins du massif du Bargy. Un modèle (stochastique) de la propagation de cette maladie dans les colonies de bouquetins de la région a donc été développé, pour aider à l'évaluation de l'efficacité des mesures de gestion sanitaire mises en place pour lutter contre la brucellose.

Régression par processus gaussiens

La régression par processus gaussiens est une méthode de régression/interpolation couramment utilisée en apprentissage statistique, statistique spatiale ou spatio-temporelle, et dans de nombreux domaines de l'ingénierie. Elle fait partie de la famille des méthodes dites « à noyau » (*kernel methods*), et se présente dans la littérature sous diverses formes plus ou moins équivalentes (splines, RBF, LS-SVM, *kernel ridge regression*…).

La régression par processus gaussiens est un outil puissant pour la construction d'émulateurs, dans le cadre d'une approche dite bayésienne. Elle repose sur une représentation probabiliste flexible qui permet de modéliser les relations complexes entre les entrées et les sorties du simulateur avec un minimum d'hypothèses a priori. En plus de prédire les résultats du simulateur, elle fournit une mesure explicite de l'incertitude associée à ces prédictions.

Une limite importante de cette méthode, dans sa forme la plus élémentaire, concerne le nombre n de points qui peut être traité — autrement dit, la taille de la base d'apprentissage — en raison de sa complexité calculatoire en $O(n^3)$ et de son occupation mémoire en $O(n^2)$. Pour surmonter cette difficulté, de très nombreuses évolutions de la méthode ont été proposées ces vingts dernières années (voir par exemple Liu et al., 2020), que l'on regroupe en anglais sous l'appellation *scalable GPs*.

Projet proposé

Le projet proposé consiste à étudier et implémenter des méthodes de régression par processus gaussiens « scalables », c'est-à-dire adaptées à des volumes de données importants. Les méthodes développées seront appliquées à l'émulation bayésienne des deux simulateurs stochastiques décrits plus haut.

Pour être un peu plus précis : la régression par processus gaussien s'appuie sur la résolution d'un système linéaire faisant intervenir la matrice de covariance des observations, qui est de taille $n \times n$, où n est le nombre d'observations disponibles. Lorsque n est grand, il en résulte des limites à l'application de la méthode, à la fois en raison du coût quadratique lié au stockage de la matrice de covariance, et du coût cubique lié aux méthodes numériques utilisée pour la résolution du système.

On se placera dans ce projet dans le régime intermédiaire où n est de l'ordre de quelques dizaines de milliers. Le stockage de la matrice de covariance reste alors faisable même sur une machine de bureau — à titre d'exemple, pour $n = 30\,000$, une matrice symétrique $n \times n$ occupe

environ 3.3 Go de mémoire en double précision — et on se concentrera sur la réduction du coût calculatoire par des méthodes issues de l'algèbre linéaire numérique, qui semblent particulièrement pertinentes dans cette plage de fonctionnement (mots-clés : approximation de rang faible, factorisation de Cholesky incomplète, algorithme de Lanczos, etc.).

Le projet se découpera en deux parties. Dans la première partie du projet, qui se déroule en S6 donc pour l'essentiel en amont du cours de ST4 sur les statistiques et l'apprentissage, on se concentrera surtout sur les aspects numériques, la fonction de covariance du processus gaussien étant donnée (par votre encadrant). Dans la deuxième partie en S7, en s'appuyant sur le cours de ST4, on pourra avoir un point de vue plus complet sur la régression par processus gaussiens, en incluant en particulier les aspects liées à choix des paramètres de la fonction de covariance.

Les développements seront réalisés dans le langage de votre choix (par exemple, Python, R, Matlan ou Julia). On prévilégiera, au moins dans un premier temps, une implémentation « directe » des méthodes étudiées (plutôt que de chercher à s'appuyer sur des packages existants pour la régression par processus gaussiens). Pour les applications, des données issues des deux simulateurs seront fournies (aucune manipulation directe des simulateurs stochastiques n'est à prévoir).

References

Evan Baker, Pierre Barbillon, Arindam Fadikar, Robert B. Gramacy, Radu Herbei, David Higdon, Jiangeng Huang, Leah R. Johnson, Pulong Ma, Anirban Mondal, Bianica Pires, Jerome Sacks, and Vadim Sokolov. Analyzing Stochastic Computer Models: A Review with Opportunities. *Statistical Science*, 37(1):64–89, 2022.

Subhasish Basak. *Multipathogen quantitative risk assessment in raw milk soft cheese : monotone integration and Bayesian optimization*. PhD thesis, Université Paris-Saclay, 2024. URL https://theses.hal.science/tel-04626447.

Sébastien Lambert, Anne Thébault, Stéphane Anselme-Martin, Clément Calenge, Charlotte Dunoyer, Luca Freddi, Bruno Garin-Bastuji, Benoit Guyonnaud, Jean Hars, Pascal Marchand, Ariane Payne, Élodie Petit, Claire Ponsart, Erwan Quéméré, Carole Toïgo, Anne van de Wiele, Sophie Rossi, and Emmanuelle Gilot-Fromont. Brucellosis in Alpine ibex: 10 years of research and expert assessments. *Médecine/Sciences*, 39(10):722–731, October 2023. doi: 10.1051/medsci/2023132. URL https://anses.hal.science/anses-04276841.

Haitao Liu, Yew-Soon Ong, Xiaobo Shen, and Jianfei Cai. When Gaussian Process Meets Big Data: A Review of Scalable GPs. *IEEE Transactions on Neural Networks and Learning Systems*, 31(11):4405–4423, 2020.